



Scraping برای جمع‌آوری مقالات علمی

۱. مقدمه

در این فاز، هدف جمع‌آوری مقالات علمی مرتبط با پنج موضوع زیر از Semantic Scholar بود:

- Foundation Models
- Generative Models
- LLM (Large Language Models)
- VLM (Vision-Language Models)
- Diffusion Models

از وب کراولینگ (Web Crawling) با Selenium برای جمع‌آوری خودکار مقالات استفاده شد. داده‌های استخراج‌شده شامل:

- عنوان مقاله (Title)
- نویسندگان (Authors)
- سال انتشار (Year)
- تعداد استنادات (Citations)
- چکیده (Abstract)
- لینک مقاله (URL)

تمام این اطلاعات در فایل‌های CSV ذخیره شدند تا در مراحل بعدی پروژه استفاده شوند.

۲. روش اجرا

۲.۱ ابزارها و تکنولوژی‌ها

Selenium WebDriver: برای تعامل با صفحات وب
Chrome WebDriver: برای اجرای خودکار مرورگر
Pandas: برای پردازش و ذخیره داده‌ها در قالب CSV
WebDriver Manager: برای مدیریت خودکار درایور کروم

۲.۲ مراحل اجرا

۱- جستجوی موضوعات:

- ورود به سایت Semantic Scholar
 - یافتن فیلد جستجو و وارد کردن نام موضوع
 - ارسال درخواست جستجو
- ۲- جمع‌آوری داده‌ها:
- دریافت مقالات نمایش داده‌شده
 - استخراج عنوان، نویسندگان، سال، استنادات، چکیده و لینک مقاله
 - فیلتر کردن مقالات قدیمی
- ۳- بارگیری مقالات بیشتر:
- استفاده از اسکروول اتوماتیک برای نمایش مقالات بیشتر
 - کلیک روی دکمه "Next Page" در صورت موجود بودن
 - انجام این کار تا زمانی که ۲۰۰۰ مقاله برای هر موضوع جمع‌آوری شود
- ۴- ذخیره داده‌ها:
- ذخیره مقالات در فایل‌های CSV جداگانه برای هر موضوع
 - ساخت پوشه‌ای مخصوص ذخیره داده‌ها

۳. چالش‌ها و راهکارها

۳.۱ چالش‌های فنی

Semantic Scholar تعداد محدودی مقاله را نمایش می‌دهد
 راهکار: استفاده از اسکروول بی‌نهایت و کلیک روی "Next Page"

محدودیت در دسترسی به نتایج زیاد
 راهکار: افزایش تعداد اسکروول‌ها و تأخیر تصادفی بین درخواست‌ها

عدم نمایش مقالات برای برخی موضوعات
 راهکار: تغییر عبارات جستجو به نام‌های مرتبط‌تر و دقیق‌تر

۴- نتایج و خروجی‌ها

فایل‌های CSV ذخیره شده:

موضوع	مقالات جمع‌آوری شده	نام فایل
Foundation Models	+۲۰۰۰	Foundation_Models.csv
Generative Models	+۲۰۰۰	Generative_Models.csv
LLM	+۸۰۰	LLM.csv
VLM	+۵۰۰	VLM.csv
Diffusion Models	+۶۰۰	Diffusion_Models.csv

۵- نتیجه‌گیری و اقدامات بعدی

- این فاز به طور کلی موفق بود و مقالات مورد نیاز از Semantic Scholar استخراج شدند.
- روش Web crawling کارآمد بود اما برخی موضوعات نیاز به جستجوی پیشرفته‌تر دارند.
- داده‌های جمع‌آوری شده برای فازهای بعدی پردازش و استفاده خواهند شد.