

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه صنعتی شریف
دانشکده مهندسی هوافضا

پروژه درس انتقال حرارت

عنوان

پیش‌بینی ضریب انتقال حرارت نانوسیالات با استفاده از الگوریتم‌های یادگیری ماشین

نگارش

شهریار محمدی - ۴۰۲۱۰۹۴۳۱

علیرضا صداقت‌پی - ۹۹۱۰۸۲۳۴

روزبه پورجعفریان - ۴۰۰۱۰۶۲۷۹

استاد درس

جناب دکتر جوادی

بهار ۱۴۰۴

پیش‌بینی ضریب انتقال حرارت نانوسیالات با استفاده از الگوریتم‌های یادگیری ماشین

چکیده

نانوسیالات به دلیل خواص حرارتی منحصر به فردشان، در بسیاری از کاربردهای صنعتی و مهندسی مورد استفاده قرار می‌گیرند. ضریب انتقال حرارت^۱ یکی از پارامترهای کلیدی در تحلیل عملکرد نانوسیالات است. هدف این پروژه طراحی یک مدل یادگیری ماشین است که بتواند با استفاده از ویژگی‌های فیزیکی و شیمیایی نانوسیالات، مقدار ضریب انتقال حرارت را پیش‌بینی کند.

^۱ Heat Transfer Coefficient

صفحه

فهرست مطالب

۱.....	مقدمه.....	۱
۲.....	تحلیل داده‌ها و پیش‌پردازش.....	۲
۲.....	۱.۲ بررسی تعداد نمونه‌ها و ویژگی‌ها.....	۲
۳.....	۲.۲ بررسی داده‌های ناقص و حذف یا جایگزینی مقادیر ناموجود.....	۳
۴.....	۳.۲ بررسی توزیع داده‌ها و شناسایی مقادیر پرت در صورت وجود.....	۴
۶.....	۴.۲ تحلیل همبستگی بین متغیرها با استفاده از ماتریس همبستگی.....	۶
۸.....	۳ پردازش داده‌ها.....	۸
۸.....	۱.۳ تبدیل داده‌های دسته‌ای به عددی با روش One-Hot Encoding.....	۸
۹.....	۲.۳ استانداردسازی داده‌های عددی با استفاده از روش MinMaxScaler.....	۹
۱۰.....	۳.۳ استانداردسازی داده‌های عددی با استفاده از روش StandardScaler.....	۱۰
۱۲.....	۴ پیاده‌سازی مدل‌های رگرسیون.....	۱۲
۱۲.....	۱.۴ تقسیم داده‌ها به مجموعه آموزش و آزمون.....	۱۲
۱۳.....	۲.۴ انتخاب و پیاده‌سازی الگوریتم‌های مختلف یادگیری ماشین.....	۱۳
۱۳.....	۱.۲.۴ رگرسیون خطی.....	۱۳
۱۵.....	۲.۲.۴ رگرسیون چند جمله‌ای.....	۱۵
۱۶.....	۳.۲.۴ رگرسیون Random Forest.....	۱۶
۱۷.....	۴.۲.۴ رگرسیون مبتنی بر شبکه عصبی.....	۱۷
۱۸.....	۳.۴ آموزش مدل و پیش‌بینی ضریب انتقال حرارت.....	۱۸
۲۰.....	۵ ارزیابی عملکرد مدل‌ها.....	۲۰
۲۰.....	۱.۵ استفاده از معیارهای ارزیابی مختلف.....	۲۰
۲۰.....	۱.۱.۵ میانگین مربعات خطا.....	۲۰
۲۰.....	۲.۱.۵ میانگین مربعات خطا.....	۲۰
۲۱.....	۳.۱.۵ ضریب تعیین.....	۲۱
۲۱.....	۲.۵ تحلیل نتایج و بررسی بهترین مدل.....	۲۱
۲۳.....	۶ نتایج و تحلیل نهایی.....	۲۳
۲۳.....	۱.۶ نمودار مقایسه مقدار واقعی و مقدار پیش‌بینی شده.....	۲۳
۲۴.....	۲.۶ بررسی مهم‌ترین ویژگی‌ها در پیش‌بینی انتقال حرارت.....	۲۴
۲۶.....	۳.۶ تحلیل نهایی و پیشنهادات برای بهبود مدل.....	۲۶
۲۶.....	۱.۳.۶ تحلیل نهایی عملکرد مدل‌ها.....	۲۶
۲۶.....	۲.۳.۶ مقایسه مدل‌ها و انتخاب بهترین مدل.....	۲۶

۲۷	پیشنهادهای برای بهبود مدل‌ها	۳.۳.۶
۲۷	نتیجه	۴.۳.۶

صفحه

فهرست اشکال

شکل ۲.۴	نمایش توزیع داده‌ها.....	۵
شکل ۲.۴	نمایش داده‌های پرت.....	۵
شکل ۲.۴	نمایش همبستگی داده‌ها.....	۷
شکل ۲.۴	نمایش استانداردسازی با روش MinMaxScaler.....	۱۰
شکل ۲.۴	نمایش استانداردسازی با روش StandardScaler.....	۱۱
شکل ۲.۴	روش رگرسیون خطی.....	۱۴
شکل ۲.۴	روش رگرسیون چندجمله‌ای.....	۱۵
شکل ۲.۴	روش رگرسیون Random Forest.....	۱۶
شکل ۲.۴	روش رگرسیون Random Forest.....	۱۷
شکل ۲.۴	آموزش مدل و پیش‌بینی.....	۱۹
شکل ۲.۴	مقایسه مدل‌ها.....	۲۲
شکل ۲.۴	بررسی مهم‌ترین ویژگی‌ها براساس Random Forest.....	۲۴
شکل ۲.۴	بررسی مهم‌ترین ویژگی‌ها براساس رگرسیون خطی.....	۲۵
شکل ۲.۴	بررسی مهم‌ترین ویژگی‌ها براساس اهمیت جایگشت.....	۲۵

۱ مقدمه

امروزه با گسترش و پیشرفت هوش مصنوعی، مهندس به سمتی حرکت کرده‌اند تا مسائل خود را با استفاده از این ابزار قدرتمند حل کنند. در این پروژه قسمت داریم تا با استفاد هاز مدل‌ها و الگوریتم‌های موجود هوش مصنوعی و روش‌های یادگیری ماشین، به پیش‌بینی ضریب انتقال حرارت در زمینه نانوسیالات پردازیم. در ادامه، خواسته‌های مطرح ده و پاسخ‌های آن‌ها آورده شده است و راجع به هر روش توضیح داده شده است.

کد نوشته شده در فایل پیوست وجود دارد و اینجا بیشتر بر روی روش‌ها و خروجی‌های نمودارها تمرکز شده است.

۲ تحلیل داده‌ها و پیش‌پردازش

در ابتدای پروژه، تحلیل داده‌ها به‌عنوان اولین گام برای درک ساختار داده‌ها و ویژگی‌های آن انجام شد. در این مرحله، ابتدا بررسی شد که آیا داده‌ها مقادیر گم‌شده یا غیرمعمول دارند و سپس اصلاحات لازم بر روی آن‌ها انجام شد. علاوه بر این، همبستگی بین ویژگی‌های مختلف مورد تحلیل قرار گرفت تا ارتباط میان ویژگی‌ها شناسایی شده و ویژگی‌های غیرضروری حذف گردید. این اقدامات به مدل کمک کرد تا بهتر به الگوهای موجود در داده‌ها پاسخ دهد. همچنین، برای مدل‌سازی روابط پیچیده‌تر بین ویژگی‌ها، ویژگی‌های تعامل و ویژگی‌های چندجمله‌ای ایجاد شدند.

پیش‌پردازش داده‌ها به‌عنوان یکی از مراحل حیاتی، برای آماده‌سازی داده‌ها جهت آموزش مدل‌ها انجام شد. در ابتدا، مقادیر گم‌شده با استفاده از روش‌های مناسب مانند میانگین‌گیری یا جایگزینی پیشین پر شدند تا هیچ داده‌ای از دست نرود. سپس، برای مدل‌هایی که به مقیاس ویژگی‌ها حساس هستند، ویژگی‌ها به‌طور استانداردسازی شدند. در این مرحله، ویژگی‌های غیرضروری حذف و ویژگی‌های مهم‌تر برای مدل انتخاب شدند تا مدل قادر به یادگیری الگوهای پیچیده به بهترین نحو ممکن باشد.

۱.۲ بررسی تعداد نمونه‌ها و ویژگی‌ها

در مراحل ابتدایی پیش‌پردازش داده‌ها، بررسی تعداد نمونه‌ها (سطرها) و ویژگی‌ها (ستون‌ها) از اهمیت زیادی برخوردار است. این کار به تحلیلگر این امکان را می‌دهد تا اطلاعات اولیه‌ای از ساختار داده‌ها بدست آورد و تصمیمات مناسبی برای مراحل بعدی پیش‌پردازش اتخاذ کند. تعداد نمونه‌ها نشان‌دهنده اندازه دیتاست است و می‌تواند به ما بگوید که آیا داده‌های کافی برای آموزش مدل وجود دارند یا خیر. اگر تعداد نمونه‌ها بسیار کم باشد، ممکن است مدل به درستی قادر به تعمیم‌سازی نباشد و دچار اورفیتینگ شود.

از سوی دیگر، تعداد ویژگی‌ها نشان‌دهنده پیچیدگی داده‌ها است و این که چه تعداد متغیر برای پیش‌بینی هدف وجود دارد. اگر تعداد ویژگی‌ها خیلی زیاد باشد، ممکن است مدل دچار افزایش پیچیدگی شود که نیاز به روش‌های انتخاب ویژگی یا کاهش ابعاد (مثل PCA) دارد. همچنین، آگاهی از تعداد ویژگی‌ها به

ما کمک می‌کند تا بررسی کنیم آیا نیاز به مهندسی ویژگی‌ها (مانند ایجاد ویژگی‌های جدید یا حذف ویژگی‌های کم‌فایده) وجود دارد یا خیر.

بنابراین، بررسی این دو عامل، یعنی تعداد نمونه‌ها و ویژگی‌ها، نقطه شروعی مهم برای درک داده‌ها و طراحی مراحل بعدی پیش‌پردازش و مدل‌سازی است.

۲.۲ بررسی داده‌های ناقص و حذف یا جایگزینی مقادیر ناموجود

در هر پروژه یادگیری ماشین، داده‌های ناقص یکی از مسائل رایج و چالش‌برانگیز هستند که می‌توانند تأثیر زیادی بر عملکرد مدل‌ها داشته باشند. بررسی داده‌های ناقص و تصمیم‌گیری در مورد نحوه مدیریت آن‌ها، مرحله‌ای اساسی در پیش‌پردازش داده‌هاست. مقادیر گمشده ممکن است به دلایل مختلفی مانند خطا در جمع‌آوری داده‌ها، نقص در سیستم‌های اندازه‌گیری یا مشکلات ارتباطی ایجاد شوند.

برای مقابله با این مشکل، چندین روش وجود دارد. در ابتدا، باید شناسایی مقادیر گمشده یا ناخالی انجام شود. این کار معمولاً با استفاده از توابع موجود در کتابخانه‌های داده‌کاوی مانند pandas، که توانایی شناسایی مقادیر NaN (Not a Number) را دارند، صورت می‌گیرد. پس از شناسایی داده‌های ناقص، دو روش اصلی برای مدیریت این مقادیر وجود دارد:

حذف داده‌های ناقص: در صورتی که تعداد داده‌های گمشده محدود باشد، ممکن است حذف ردیف‌هایی که حاوی مقادیر گمشده هستند، منطقی باشد. این کار از کاهش داده‌ها جلوگیری کرده و می‌تواند سرعت پردازش را افزایش دهد.

جایگزینی مقادیر گمشده: در بسیاری از موارد، جایگزینی مقادیر گمشده با میانگین، میانه یا مد ویژگی‌های دیگر می‌تواند روش مناسبی باشد. همچنین، در صورت لزوم، از مدل‌های پیچیده‌تری مانند پیش‌بینی مقادیر گمشده با استفاده از رگرسیون یا یادگیری ماشین می‌توان برای پر کردن این مقادیر استفاده کرد.

در نهایت، این تصمیمات به ویژگی‌های داده‌ها، تعداد مقادیر گمشده و هدف مدل بستگی دارد. بررسی دقیق داده‌های ناقص و اتخاذ تصمیمات صحیح در این مرحله می‌تواند تأثیر زیادی بر دقت و عملکرد نهایی مدل داشته باشد.


۳.۲ بررسی توزیع داده‌ها و شناسایی مقادیر پرت در صورت وجود

بررسی توزیع داده‌ها و شناسایی مقادیر پرت (Outliers) یکی از مراحل حیاتی در پیش‌پردازش داده‌ها است که می‌تواند تأثیر زیادی بر دقت مدل‌های یادگیری ماشین داشته باشد. مقادیر پرت به نقاط داده‌ای اطلاق می‌شود که به طور قابل توجهی از سایر داده‌ها دور هستند و ممکن است بر رفتار مدل تأثیر منفی بگذارند. این مقادیر می‌توانند ناشی از خطاهای اندازه‌گیری، اشتباهات انسانی یا حتی ویژگی‌های واقعی داده‌ها باشند.


در ابتدا، برای بررسی توزیع داده‌ها از تکنیک‌های آماری مانند رسم هیستوگرام یا نمودار جعبه‌ای (Box Plot) استفاده می‌شود تا الگوی کلی داده‌ها و مقادیر پرت شناسایی شوند. این نمودارها به تحلیلگر کمک می‌کنند تا متوجه شود که آیا داده‌ها به طور نرمال توزیع شده‌اند یا خیر، و در صورت وجود توزیع غیرعادی، تصمیمات مناسبی گرفته شود.

در مرحله بعدی، شناسایی مقادیر پرت با استفاده از معیارهایی مانند مقدار ۱.۵ برابر فاصله بین چارک‌ها (IQR) یا استفاده از معیار Z-score انجام می‌شود. مقادیر پرت به‌طور معمول مقادیری هستند که از توزیع اصلی داده‌ها به شدت فاصله دارند. به عنوان مثال، اگر Z-score یک داده بزرگتر از ۳ یا کوچکتر از -۳ باشد، آن داده به‌عنوان مقدار پرت در نظر گرفته می‌شود.

پس از شناسایی مقادیر پرت، تصمیم‌گیری در مورد چگونگی برخورد با آن‌ها باید انجام شود. در برخی موارد، مقادیر پرت ممکن است نشان‌دهنده خطای داده‌برداری باشند که می‌توان آن‌ها را حذف کرد، اما در سایر مواقع، این مقادیر می‌توانند اطلاعات مفیدی را نمایان کنند و باید در مدل‌سازی نگه داشته شوند. تصمیم در این زمینه به نوع داده‌ها، مدل انتخابی و هدف از پیش‌بینی بستگی دارد.



شکل ۱.۲ نمایش توزیع داده‌ها



شکل ۲.۲ نمایش داده‌های پرت


۴.۲ تحلیل همبستگی بین متغیرها با استفاده از ماتریس همبستگی

تحلیل همبستگی یکی از مراحل مهم در تحلیل داده‌ها است که به کمک آن می‌توان فهمید که آیا بین ویژگی‌ها (متغیرهای ورودی) و متغیر هدف یا بین خود ویژگی‌ها، روابط معناداری وجود دارد یا خیر. این تحلیل به‌ویژه در مدل‌سازی‌های یادگیری ماشین بسیار مفید است، زیرا می‌تواند به شناسایی ویژگی‌های مرتبط و غیرمفید کمک کند و در نهایت باعث بهبود عملکرد مدل شود. یکی از ابزارهای رایج برای تحلیل همبستگی، استفاده از ماتریس همبستگی است.

ماتریس همبستگی یک جدول است که در آن مقدار همبستگی بین هر جفت از ویژگی‌ها و متغیر هدف محاسبه می‌شود. مقادیر همبستگی بین -۱ و ۱ قرار دارند. اگر مقدار همبستگی نزدیک به ۱ باشد، نشان‌دهنده یک رابطه مثبت قوی است، یعنی با افزایش یکی از ویژگی‌ها، دیگری نیز افزایش می‌یابد. مقادیر نزدیک به -۱ نشان‌دهنده رابطه منفی است، و مقادیر نزدیک به ۰ نشان‌دهنده عدم وجود رابطه خطی است.

در ماتریس همبستگی، می‌توان روابط غیرخطی را مشاهده نکرد، اما این روش یک ابزار اولیه برای شناسایی روابط خطی بین ویژگی‌ها و متغیر هدف است.

در این کد، ابتدا با استفاده از متد `corr()`، ماتریس همبستگی داده‌ها محاسبه می‌شود. این ماتریس همبستگی نشان‌دهنده روابط خطی بین ویژگی‌های مختلف است. سپس، با استفاده از کتابخانه `seaborn`، یک نمودار حرارتی (`Heatmap`) از ماتریس همبستگی رسم می‌شود که به‌صورت گرافیکی نشان می‌دهد که هر ویژگی چقدر با ویژگی‌های دیگر یا هدف همبستگی دارد. با این روش می‌توان به راحتی روابط موجود بین ویژگی‌ها را مشاهده کرد.



شکل ۳.۲ نمایش همبستگی داده‌ها

۳ پردازش داده‌ها

پردازش داده‌ها یکی از مراحل کلیدی در پیش‌پردازش داده‌هاست که هدف آن آماده‌سازی داده‌ها برای مدل‌سازی است. این مرحله شامل عملیات مختلفی مانند جایگزینی مقادیر گمشده، استانداردسازی ویژگی‌ها و ایجاد ویژگی‌های جدید است. برای مثال، اگر در داده‌ها مقادیر گمشده‌ای وجود داشته باشد، این مقادیر می‌توانند با میانگین، میانه یا مد ویژگی‌های مربوطه جایگزین شوند. همچنین، در مدل‌هایی مانند شبکه‌های عصبی که به مقیاس ویژگی‌ها حساس هستند، ویژگی‌ها باید به‌طور استانداردسازی شوند تا مدل بتواند به‌طور بهینه‌تر یاد بگیرد. ایجاد ویژگی‌های جدید، مانند ویژگی‌های تعامل یا ویژگی‌های چندجمله‌ای، می‌تواند روابط پیچیده‌تری را در داده‌ها مدل کند.

پردازش داده‌ها همچنین شامل تقسیم داده‌ها به مجموعه‌های آموزشی و آزمایشی برای ارزیابی صحیح مدل است. این کار به مدل کمک می‌کند تا از داده‌های آموزشی برای یادگیری استفاده کرده و عملکرد خود را بر روی داده‌های آزمایشی ارزیابی کند. علاوه بر این، کاهش ابعاد (با استفاده از تکنیک‌هایی مانند PCA) و انتخاب ویژگی‌ها به کاهش پیچیدگی مدل کمک می‌کند و باعث بهبود سرعت و دقت مدل می‌شود. پردازش داده‌ها باید به‌طور دقیق و بر اساس نیازهای مدل انجام شود تا بهترین نتیجه از یادگیری ماشین به‌دست آید.

۱.۳ تبدیل داده‌های دسته‌ای به عددی با روش One-Hot Encoding

در بسیاری از مدل‌های یادگیری ماشین، ویژگی‌های دسته‌ای (categorical) باید به ویژگی‌های عددی تبدیل شوند تا مدل بتواند از آن‌ها استفاده کند. یکی از روش‌های رایج برای تبدیل داده‌های دسته‌ای به عددی، استفاده از One-Hot Encoding است. این روش به‌طور خاص برای ویژگی‌هایی مناسب است که مقادیر گسسته (مانند جنسیت یا کشور) دارند. در این روش، به ازای هر مقدار متمایز در یک ویژگی دسته‌ای، یک ستون جدید ایجاد می‌شود که مقادیر آن برابر با ۱ یا ۰ است. به عبارت دیگر، به جای استفاده از یک مقدار عددی که تمام مقادیر مختلف را در یک عدد قرار دهد، از چند ستون باینری استفاده می‌شود که نشان‌دهنده حضور یا عدم حضور یک مقدار خاص در ویژگی است.

برای مثال، اگر ویژگی "رنگ" دارای مقادیر "قرمز"، "آبی" و "سبز" باشد، پس از اعمال One-Hot Encoding سه ستون جدید با مقادیر ۱ یا ۰ ایجاد می‌شود: یکی برای "قرمز"، یکی برای "آبی" و یکی برای "سبز". اگر رنگ یک نمونه "قرمز" باشد، ستون "قرمز" برابر ۱ و سایر ستون‌ها برابر ۰ خواهند بود. این روش به مدل اجازه می‌دهد تا روابط بین مقادیر مختلف ویژگی‌ها را به‌طور مستقل و مؤثر یاد بگیرد. در این کد، ابتدا ستون‌های دستوری (categorical columns) دیتاست شناسایی می‌شوند با استفاده از تابع `select_dtypes(include='object')` که تنها ستون‌هایی که نوع داده آن‌ها 'object' است (معمولاً ویژگی‌های دستوری) را انتخاب می‌کند. سپس، با استفاده از تابع `pd.get_dummies()` و اعمال آن بر روی ستون‌های دستوری، داده‌ها با استفاده از روش One-Hot Encoding تبدیل به داده‌های عددی می‌شوند. در این کد، از `drop_first=True` استفاده شده تا یکی از مقادیر هر ویژگی حذف شود و از "دامپینگ" (multicollinearity) جلوگیری کند. در نهایت، پنج ردیف اول داده‌های کدگذاری‌شده با استفاده از `head()` نمایش داده می‌شود.

۲.۳ استانداردسازی داده‌های عددی با استفاده از روش MinMaxScaler


استانداردسازی داده‌ها یکی از مراحل مهم پیش‌پردازش است که هدف آن مقیاس‌دهی به داده‌ها برای استفاده بهتر در مدل‌های یادگیری ماشین است. یکی از روش‌های استانداردسازی، MinMaxScaler است که ویژگی‌ها را به یک بازه خاص (معمولاً بین ۰ و ۱) مقیاس‌دهی می‌کند. این روش با توجه به حداقل و حداکثر هر ویژگی، داده‌ها را به مقیاس ۰ تا ۱ تغییر می‌دهد. به عنوان مثال، اگر ویژگی‌ای دارای مقادیر ۱۰۰ و ۵۰۰ باشد، با استفاده از MinMaxScaler، این مقادیر به ترتیب به ۰ و ۱ مقیاس‌دهی خواهند شد.

این روش به‌ویژه برای مدل‌هایی که نیاز به مقیاس‌دهی داده‌ها دارند (مانند شبکه‌های عصبی و الگوریتم‌های مبتنی بر مسافت مثل K-نزدیک‌ترین همسایه) مفید است. همچنین، MinMaxScaler باعث می‌شود که داده‌ها برای محاسبات مدل‌های یادگیری ماشین بهینه‌تر شوند و سرعت آموزش مدل افزایش یابد. به علاوه، استفاده از این روش می‌تواند از مشکلات ناشی از مقیاس‌های متفاوت ویژگی‌ها جلوگیری کند.

در این کد ابتدا با استفاده از `drop()`، ویژگی‌ها (X) از متغیر هدف (y) جدا می‌شوند. سپس، MinMaxScaler() از کتابخانه scikit-learn برای مقیاس‌دهی ویژگی‌ها به بازه [۰, ۱] مورد استفاده

قرار می‌گیرد. تابع `fit_transform` برای مقیاس‌دهی داده‌ها بین ۰ و ۱ به کار می‌رود و داده‌های مقیاس‌دهی‌شده به یک `DataFrame` تبدیل می‌شوند تا قابل مشاهده و بررسی باشند.

در ادامه، با استفاده از `matplotlib` و `seaborn`، توزیع ویژگی `Flow_Rate` قبل و بعد از مقیاس‌دهی به‌طور گرافیکی مقایسه می‌شود. در نهایت، چند ردیف اول داده‌های مقیاس‌دهی‌شده برای بررسی بیشتر نمایش داده می‌شود.



شکل ۱.۳ نمایش استانداردسازی با روش `MinMaxScaler`


۳.۳ استانداردسازی داده‌های عددی با استفاده از روش `StandardScaler`

استانداردسازی داده‌ها یکی از تکنیک‌های پیش‌پردازش مهم است که برای بسیاری از الگوریتم‌های یادگیری ماشین ضروری است. یکی از روش‌های رایج برای استانداردسازی داده‌ها، استفاده از `StandardScaler` است که داده‌ها را به گونه‌ای تغییر می‌دهد که میانگین آن‌ها برابر با صفر و انحراف معیار برابر با یک باشد. این روش باعث می‌شود که ویژگی‌ها با مقیاس‌های مختلف به مقیاس یکسانی تبدیل شوند و الگوریتم‌های یادگیری ماشین که حساس به مقیاس ویژگی‌ها هستند، بهتر عمل کنند.

روش `StandardScaler` از میانگین و انحراف معیار هر ویژگی استفاده می‌کند تا ویژگی‌ها را استانداردسازی کند. این به معنای آن است که برای هر ویژگی، مقادیر داده از میانگین آن ویژگی کم شده و سپس بر انحراف معیار آن تقسیم می‌شود. این فرآیند باعث می‌شود که داده‌ها در یک مقیاس مشابه قرار بگیرند، که برای الگوریتم‌هایی مانند رگرسیون خطی و شبکه‌های عصبی ضروری است، زیرا این الگوریتم‌ها به مقیاس داده‌ها حساس هستند.

در این کد ابتدا ویژگی‌ها (X) از متغیر هدف (y) جدا می‌شوند و سپس از `StandardScaler` برای استانداردسازی داده‌ها استفاده می‌شود. با استفاده از `fit_transform()`، ویژگی‌ها به گونه‌ای مقیاس‌دهی می‌شوند که میانگین آن‌ها صفر و انحراف معیار یک شود. سپس، داده‌های استانداردسازی شده به یک `DataFrame` تبدیل می‌شوند تا برای بررسی آسان‌تر باشند.

بعد از آن، برای مقایسه، توزیع ویژگی `Flow_Rate` قبل و بعد از استانداردسازی با استفاده از نمودار هیستوگرام رسم می‌شود. این مقایسه کمک می‌کند تا تفاوت‌ها در توزیع داده‌ها قبل و بعد از استانداردسازی مشاهده شود. در پایان، چند ردیف اول داده‌های استانداردسازی شده برای نمایش نتایج به نمایش درمی‌آید.



شکل ۲.۳ نمایش استانداردسازی با روش `StandardScaler`

۴ پیاده سازی مدل های رگرسیون

رگرسیون یکی از تکنیک های پایه ای در یادگیری ماشین است که برای پیش بینی مقادیر پیوسته از داده ها استفاده می شود. در این بخش از پروژه، مدل های مختلف رگرسیون برای پیش بینی ضریب انتقال حرارت از داده ها استفاده شدند. ابتدا، مدل رگرسیون خطی به عنوان یک مدل پایه ای پیاده سازی شد تا به بررسی رابطه خطی بین ویژگی ها و هدف پرداخته شود. سپس مدل های پیچیده تری مانند رگرسیون چندجمله ای، که قابلیت مدل سازی روابط غیرخطی را دارا است، استفاده شدند. همچنین، به منظور تحلیل پیچیدگی های غیرخطی داده ها و بررسی قدرت مدل های پیچیده تر، از مدل های درخت تصادفی (Random Forest) و شبکه عصبی (Neural Network) نیز استفاده شد.

پیاده سازی این مدل ها شامل مراحل مختلفی از جمله تقسیم داده ها به مجموعه های آموزشی و آزمایشی، انتخاب ویژگی های مناسب، آموزش مدل ها و در نهایت ارزیابی آن ها با استفاده از معیارهایی مانند میانگین مربع خطا (MSE) و ضریب تعیین (R^2) بود. هدف اصلی این فرایند، مقایسه مدل های مختلف و شناسایی مدل هایی بود که بهترین عملکرد را در پیش بینی ضریب انتقال حرارت نشان دهند. هر مدل با استفاده از تنظیمات خاص خود و پس از انجام تنظیمات هایپرپارامتر، بهینه سازی شده و نتایج آن در نهایت برای انتخاب بهترین مدل مورد استفاده قرار گرفت.

۱.۴ تقسیم داده ها به مجموعه آموزش و آزمون

تقسیم داده ها به مجموعه های آموزش و آزمون یکی از مراحل اساسی در ارزیابی عملکرد مدل های یادگیری ماشین است. این فرآیند به طور عمده برای جلوگیری از اورفیتینگ (Overfitting) انجام می شود. در این مرحله، داده ها به دو بخش تقسیم می شوند: بخش آموزش که برای آموزش مدل استفاده می شود و بخش آزمون که برای ارزیابی عملکرد مدل پس از آموزش استفاده می شود. به طور معمول، داده ها به دو بخش تقسیم می شوند: ۸۰٪ برای آموزش و ۲۰٪ برای آزمون.

در کد ارائه شده، ابتدا ویژگی ها (X) و متغیر هدف (y) از داده ها جدا می شوند. سپس با استفاده از تابع `train_test_split` از کتابخانه `scikit-learn`، داده ها به دو بخش تقسیم می شوند: ۸۰٪ از داده ها برای مجموعه آموزش و ۲۰٪ برای مجموعه آزمون اختصاص می یابد. این تقسیم بندی به طور تصادفی انجام

می‌شود تا از انتخاب نمونه‌های خاص جلوگیری شود و مدل توانایی تعمیم‌پذیری به داده‌های جدید را داشته باشد. در نهایت، اندازه مجموعه‌های آموزش و آزمون به نمایش گذاشته می‌شود تا بررسی شود که داده‌ها به درستی تقسیم شده‌اند.


۲.۴ انتخاب و پیاده‌سازی الگوریتم‌های مختلف یادگیری ماشین

در این بخش از پروژه، هدف انتخاب و پیاده‌سازی چندین الگوریتم مختلف یادگیری ماشین است تا به بهترین مدل برای پیش‌بینی ضریب انتقال حرارت برسیم. انتخاب الگوریتم‌های مناسب بستگی به ماهیت داده‌ها، پیچیدگی مدل، و نوع مسئله (در اینجا پیش‌بینی عددی) دارد. به‌طور کلی، برای مدل‌سازی داده‌های عددی و پیش‌بینی مقادیر پیوسته، چندین الگوریتم پرکاربرد وجود دارد که در این پروژه پیاده‌سازی شدند.

۱.۲.۴ رگرسیون خطی

به‌عنوان یک مدل پایه‌ای، رگرسیون خطی برای بررسی وجود هر گونه رابطه خطی بین ویژگی‌ها و متغیر هدف استفاده شد. این مدل به دلیل سادگی و قابلیت تفسیر بالا، معمولاً به‌عنوان نقطه شروع در بسیاری از مسائل رگرسیونی به کار می‌رود.

در این کد، مدل رگرسیون خطی از کتابخانه scikit-learn پیاده‌سازی و آموزش داده می‌شود. ابتدا ویژگی‌ها و متغیر هدف از داده‌ها جدا می‌شوند، سپس مدل بر اساس داده‌های آموزشی آموزش می‌بیند. پس از آن، مدل برای پیش‌بینی ضریب انتقال حرارت بر اساس داده‌های آزمون استفاده می‌شود و عملکرد آن با استفاده از معیارهای میانگین مربع خطا (MSE) و ضریب تعیین (R^2) ارزیابی می‌شود. در نهایت، نمودار پراکندگی بین مقادیر واقعی و پیش‌بینی‌شده رسم می‌شود تا دقت مدل به‌طور بصری نمایش داده شود.




شکل ۱.۴ روش رگرسیون خطی

۲.۲.۴ رگرسیون چند جمله‌ای

برای این مدل، ابتدا ویژگی‌ها به درجه‌های بالاتر ارتقا داده شدند و سپس رگرسیون خطی روی این ویژگی‌های جدید اعمال شد. عملکرد مدل با مقایسه پیش‌بینی‌های آن بر اساس داده‌های آزمون ارزیابی شد.

در این کد، ابتدا ویژگی‌های چندجمله‌ای با درجه ۲ با استفاده از `PolynomialFeatures` ایجاد می‌شود تا روابط غیرخطی بین ویژگی‌ها و متغیر هدف مدل‌سازی شود. سپس، مدل رگرسیون خطی روی این ویژگی‌های چندجمله‌ای آموزش داده می‌شود و پیش‌بینی‌هایی برای داده‌های آزمون انجام می‌شود. پس از آن، عملکرد مدل با استفاده از میانگین مربع خطا (MSE) و ضریب تعیین (R^2) ارزیابی می‌شود. در نهایت، نتایج پیش‌بینی‌ها با استفاده از نمودار پراکندگی نمایش داده می‌شود تا مقایسه‌ای بین مقادیر واقعی و پیش‌بینی‌شده انجام گیرد و دقت مدل نشان داده شود.




شکل ۲.۴ روش رگرسیون چندجمله‌ای

۳.۲.۴ رگرسیون Random Forest

این الگوریتم یک مدل تجمعی است که از چندین درخت تصمیم برای پیش‌بینی استفاده می‌کند. به دلیل قدرت آن در مدل‌سازی روابط پیچیده و توانایی مقابله با داده‌های غیرخطی، درخت تصادفی یکی از بهترین گزینه‌ها برای این پروژه بود. همچنین، این مدل به طور خودکار ویژگی‌های مهم را شناسایی می‌کند.

در این کد، ابتدا مدل رگرسیون درخت تصادفی (Random Forest Regressor) با ۱۰۰ درخت و تنظیمات ثابت برای `random_state` ایجاد می‌شود. سپس، مدل با استفاده از داده‌های آموزشی آموزش داده می‌شود. پس از آموزش، مدل برای پیش‌بینی داده‌های آزمون استفاده می‌شود و پیش‌بینی‌ها محاسبه می‌شود. عملکرد مدل با استفاده از دو معیار میانگین مربع خطا (MSE) و ضریب تعیین (R^2) ارزیابی شده و در نهایت، نمودار پراکندگی بین مقادیر واقعی و پیش‌بینی شده رسم می‌شود تا دقت مدل بصری‌سازی شود. همچنین، MSE و R^2 به طور عددی چاپ می‌شود تا نتایج مدل نمایش داده شود.




شکل ۳.۴ روش رگرسیون Random Forest

۴.۲.۴ رگرسیون مبتنی بر شبکه عصبی

در این مدل، چندین درخت تصمیم به‌طور مستقل آموزش دیدند و نتایج آن‌ها برای پیش‌بینی نهایی ترکیب شدند. رگرسیون درخت تصادفی به‌طور خاص برای شبیه‌سازی روابط پیچیده غیرخطی بسیار مفید است.

در این کد، ابتدا مدل رگرسیون شبکه عصبی (MLPRegressor) با یک لایه مخفی حاوی ۱۰۰ نورون و حداکثر ۱۰۰۰ تکرار برای آموزش ایجاد می‌شود. سپس، مدل با استفاده از داده‌های آموزشی آموزش داده می‌شود. بعد از آموزش، مدل برای پیش‌بینی داده‌های آزمون استفاده می‌شود و پیش‌بینی‌ها محاسبه می‌شوند. عملکرد مدل با استفاده از دو معیار میانگین مربع خطا (MSE) و ضریب تعیین (R^2) ارزیابی شده و در نهایت، نمودار پراکندگی بین مقادیر واقعی و پیش‌بینی‌شده رسم می‌شود تا دقت مدل بصری‌سازی گردد. همچنین، MSE و R^2 به‌طور عددی چاپ می‌شود تا نتایج مدل نمایش داده شود




شکل ۴.۴ روش رگرسیون Random Forest

۳.۴ آموزش مدل و پیش‌بینی ضریب انتقال حرارت

در این بخش از پروژه، هدف آموزش مدل‌های یادگیری ماشین و استفاده از آن‌ها برای پیش‌بینی ضریب انتقال حرارت است. پس از آماده‌سازی داده‌ها و پیش‌پردازش آن‌ها (شامل تقسیم داده‌ها به مجموعه‌های آموزش و آزمون، استانداردسازی ویژگی‌ها، و انجام مهندسی ویژگی‌ها)، مدل‌های مختلف یادگیری ماشین بر اساس داده‌های آموزشی آموزش داده می‌شوند. این مدل‌ها شامل رگرسیون خطی، رگرسیون چندجمله‌ای، درخت تصادفی و شبکه‌های عصبی هستند که هر کدام برای یادگیری الگوهای مختلف از داده‌ها استفاده می‌کنند.

آموزش مدل به این معنی است که مدل با استفاده از داده‌های آموزشی ویژگی‌ها را می‌آموزد و ضرایب یا پارامترهای مدل را به گونه‌ای به روز می‌کند که کمترین خطا را در پیش‌بینی‌های خود داشته باشد. پس از آموزش، مدل با استفاده از داده‌های آزمون برای پیش‌بینی ضریب انتقال حرارت ارزیابی می‌شود. پیش‌بینی‌های انجام شده سپس با استفاده از معیارهایی مانند میانگین مربع خطا (MSE) و ضریب تعیین (R^2) ارزیابی می‌شوند تا دقت و عملکرد مدل مورد بررسی قرار گیرد. در نهایت، مدل‌هایی که بهترین نتایج را ارائه می‌دهند انتخاب می‌شوند و می‌توانند برای پیش‌بینی ضریب انتقال حرارت در داده‌های جدید استفاده شوند.

در این کد، چهار مدل مختلف رگرسیون برای پیش‌بینی ضریب انتقال حرارت پیاده‌سازی و ارزیابی شده‌اند. ابتدا داده‌ها به دو مجموعه آموزش و آزمون تقسیم می‌شوند. سپس، مدل‌های رگرسیون خطی، رگرسیون چندجمله‌ای (با استفاده از ویژگی‌های چندجمله‌ای)، درخت تصادفی و شبکه عصبی آموزش داده می‌شوند. پس از آموزش، پیش‌بینی‌ها انجام شده و عملکرد هر مدل با استفاده از معیارهای میانگین مربع خطا (MSE) و ضریب تعیین (R^2) ارزیابی می‌شود. در نهایت، نمودار پراکندگی بین مقادیر واقعی و پیش‌بینی‌شده برای هر مدل رسم می‌شود تا دقت پیش‌بینی‌ها به‌طور بصری مقایسه گردد. نتایج MSE و R^2 برای هر مدل در کنسول چاپ می‌شوند تا عملکرد هر مدل به‌طور دقیق‌تر بررسی شود.



شکل ۵.۴ آموزش مدل و پیشبینی

۵ ارزیابی عملکرد مدل‌ها

برای ارزیابی دقت و کارایی مدل‌های یادگیری ماشین، از معیارهای مختلف ارزیابی استفاده می‌شود که هر کدام به نحوی توانایی مدل را در پیش‌بینی مقادیر صحیح اندازه‌گیری می‌کنند. در این پروژه، سه معیار مهم برای ارزیابی مدل‌ها استفاده شده‌اند که شامل میانگین مربعات خطا (MSE)، میانگین قدر مطلق خطا (MAE) و ضریب تعیین (R^2) هستند.

۱.۵ استفاده از معیارهای ارزیابی مختلف

برای ارزیابی دقت و کارایی مدل‌های یادگیری ماشین، از معیارهای مختلف ارزیابی استفاده می‌شود که هر کدام به نحوی توانایی مدل را در پیش‌بینی مقادیر صحیح اندازه‌گیری می‌کنند. در این پروژه، سه معیار مهم برای ارزیابی مدل‌ها استفاده شده‌اند که شامل میانگین مربعات خطا (MSE)، میانگین قدر مطلق خطا (MAE) و ضریب تعیین (R^2) هستند.

۱.۱.۵ میانگین مربعات خطا

MSE یکی از رایج‌ترین معیارها برای ارزیابی مدل‌های رگرسیونی است. این معیار به صورت میانگین مربعات اختلاف بین پیش‌بینی‌های مدل و مقادیر واقعی محاسبه می‌شود. هرچه مقدار MSE کمتر باشد، نشان‌دهنده دقت بیشتر مدل است. این معیار حساس به مقادیر بزرگ خطا است، به این معنی که اگر پیش‌بینی‌ها بسیار اشتباه باشند، تاثیر زیادی بر نتیجه خواهد داشت.

۲.۱.۵ میانگین مربعات خطا

MAE معیار دیگری است که میزان خطای پیش‌بینی‌ها را با استفاده از قدر مطلق اختلاف بین پیش‌بینی‌ها و مقادیر واقعی محاسبه می‌کند. برخلاف MSE که به اشتباهات بزرگ توجه بیشتری می‌کند، MAE تاثیر همه خطاها را به‌طور یکسان در نظر می‌گیرد. این معیار ساده‌تر از MSE است و به راحتی قابل تفسیر است، زیرا واحد آن مشابه با واحد داده‌ها است.

۳.۱.۵ ضریب تعیین

R^2 یا ضریب تعیین معیاری است که نشان می‌دهد چه درصدی از واریانس داده‌های هدف توسط مدل توضیح داده شده است. این معیار بین ۰ و ۱ قرار دارد و هرچه مقدار R^2 به ۱ نزدیک‌تر باشد، مدل بهتری است. اگر R^2 برابر با ۱ باشد، مدل کاملاً داده‌ها را پیش‌بینی کرده است، در حالی که اگر مقدار آن ۰ باشد، مدل هیچ ارتباطی با داده‌ها ندارد. این معیار به‌طور ویژه در مدل‌های رگرسیونی مفید است.

در این پروژه، پس از آموزش مدل‌ها (مانند رگرسیون خطی، رگرسیون چندجمله‌ای، درخت تصادفی و شبکه عصبی)، از این سه معیار برای ارزیابی دقت مدل‌ها استفاده شد. MSE و MAE میزان خطای پیش‌بینی‌ها را اندازه‌گیری می‌کنند، در حالی که R^2 نشان‌دهنده میزان تطابق مدل با داده‌ها است. با مقایسه این معیارها برای هر مدل، می‌توان انتخاب کرد که کدام مدل بهترین عملکرد را داشته است و پیش‌بینی‌های دقیقی ارائه داده است.


۲.۵ تحلیل نتایج و بررسی بهترین مدل

پس از ارزیابی مدل‌ها با استفاده از معیارهای مختلف مانند میانگین مربعات خطا (MSE)، میانگین قدر مطلق خطا (MAE) و ضریب تعیین (R^2)، نتایج به دست آمده از هر مدل مورد بررسی قرار گرفت. این معیارها به ما کمک می‌کنند تا عملکرد هر مدل را بسنجیم و تصمیم بگیریم که کدام مدل بهترین پیش‌بینی را برای ضریب انتقال حرارت ارائه می‌دهد.

مدل‌های مختلفی که در این پروژه آزمایش شدند، شامل رگرسیون خطی، رگرسیون چندجمله‌ای، درخت تصادفی و شبکه عصبی بودند. در ابتدا، عملکرد مدل‌های ساده‌تر مانند رگرسیون خطی مورد بررسی قرار گرفت، اما به دلیل پیچیدگی‌های داده‌ها و روابط غیرخطی موجود، مدل‌هایی مانند رگرسیون چندجمله‌ای و درخت تصادفی عملکرد بهتری ارائه دادند. به‌ویژه، درخت تصادفی به دلیل توانایی در مدل‌سازی روابط پیچیده غیرخطی و جلوگیری از اورفیتینگ ($Overfitting$)، بهترین عملکرد را در مقایسه با سایر مدل‌ها نشان داد.

شبکه عصبی نیز به‌عنوان یک مدل پیچیده، توانست پیش‌بینی‌های دقیقی ارائه دهد، اما به دلیل نیاز به تنظیمات بیشتری و داده‌های بیشتر، در برخی موارد ممکن بود به اندازه مدل‌های دیگر عمل نکند. با این حال، در مجموع، درخت تصادفی به‌عنوان بهترین مدل انتخاب شد چرا که توانست ترکیب بهتری از دقت و تعمیم‌پذیری را ارائه دهد.

در نهایت، با توجه به نتایج حاصل از ارزیابی مدل‌ها، مدل درخت تصادفی به‌عنوان بهترین مدل برای پیش‌بینی ضریب انتقال حرارت انتخاب شد. این مدل نشان داد که می‌تواند به‌طور مؤثری پیچیدگی‌های داده‌ها را درک کرده و پیش‌بینی‌هایی دقیق ارائه دهد.



شکل ۱.۵ مقایسه مدل‌ها

۶ نتایج و تحلیل نهایی

۱.۶ نمودار مقایسه مقدار واقعی و مقدار پیش‌بینی شده


نمودار مقایسه مقدار واقعی و مقدار پیش‌بینی شده به‌عنوان ابزاری بصری برای ارزیابی عملکرد مدل‌ها استفاده می‌شود. این نمودار به‌طور معمول به صورت نمودار پراکندگی (scatter plot) طراحی می‌شود که در آن مقدار واقعی (از داده‌های آزمون) در محور X و مقدار پیش‌بینی شده (توسط مدل) در محور Y قرار می‌گیرد. این نمودار به ما این امکان را می‌دهد تا به‌طور مستقیم مشاهده کنیم که پیش‌بینی‌های مدل چقدر به مقادیر واقعی نزدیک هستند. اگر مدل عملکرد خوبی داشته باشد، نقاط باید به‌طور نزدیک به خط هویت (identity line) قرار گیرند که در آن مقادیر پیش‌بینی شده دقیقاً برابر با مقادیر واقعی هستند.

در این پروژه، برای هر مدل (رگرسیون خطی، رگرسیون چندجمله‌ای، درخت تصادفی و شبکه عصبی)، نمودارهای مقایسه‌ای بین مقادیر واقعی و مقادیر پیش‌بینی شده رسم شده است. این نمودارها به‌طور بصری نشان می‌دهند که کدام مدل‌ها قادر به پیش‌بینی دقیق‌تری از ضریب انتقال حرارت هستند. به‌طور خاص، خط هویت در نمودار پراکندگی به‌صورت خط قرمز نقطه‌چین رسم شده است و هر چه فاصله بین نقاط پیش‌بینی شده و این خط کمتر باشد، مدل دقت بیشتری دارد.


این کد چهار نمودار پراکندگی (scatter plots) را برای مقایسه مقادیر واقعی و پیش‌بینی شده برای هر یک از مدل‌های رگرسیون خطی، رگرسیون چندجمله‌ای، درخت تصادفی و شبکه عصبی رسم می‌کند. برای هر مدل، ابتدا نمودار پراکندگی رسم می‌شود که مقادیر واقعی در محور X و مقادیر پیش‌بینی شده در محور Y قرار دارند. خط هویت (که به صورت خط قرمز نقطه‌چین نمایش داده شده) در هر نمودار کشیده می‌شود تا نشان دهد که پیش‌بینی‌های مدل چقدر به مقادیر واقعی نزدیک هستند. سپس، `plt.subplot` برای قرار دادن نمودارها در یک چیدمان 2×2 استفاده می‌شود. در نهایت، `plt.tight_layout` برای تنظیم فضای مناسب بین نمودارها و `plt.show` برای نمایش آن‌ها استفاده می‌شود. این نمودارها به‌طور بصری کمک می‌کنند تا عملکرد هر مدل به راحتی مقایسه شود.

۲.۶ بررسی مهم‌ترین ویژگی‌ها در پیش‌بینی انتقال حرارت


در این کد، مهم‌ترین ویژگی‌ها در پیش‌بینی ضریب انتقال حرارت با استفاده از دو روش مختلف ارزیابی می‌شوند: رگرسیون خطی و اهمیت ویژگی‌ها با استفاده از روش جایگشتی (Permutation Importance). ابتدا، برای مدل رگرسیون خطی، ضرایب هر ویژگی استخراج می‌شوند و سپس بر اساس مقدار مطلق ضرایب، اهمیت هر ویژگی مشخص می‌شود. ویژگی‌هایی که ضرایب بزرگ‌تری دارند، اهمیت بیشتری در پیش‌بینی دارند. این اطلاعات در یک DataFrame ذخیره می‌شوند و سپس با استفاده از یک نمودار افقی (barh) نمایش داده می‌شود که در آن ویژگی‌های مهم‌تر در بالای نمودار قرار می‌گیرند. در مرحله بعدی، برای مدل درخت تصادفی، از روش جایگشتی برای محاسبه اهمیت ویژگی‌ها استفاده می‌شود. این روش با انجام چندین پیش‌بینی و جایگزینی ویژگی‌ها، میزان تغییرات در پیش‌بینی‌ها را محاسبه می‌کند و ویژگی‌هایی که بیشترین تأثیر را دارند شناسایی می‌شوند. نتایج این تحلیل نیز در یک DataFrame ذخیره و بر اساس اهمیت ویژگی‌ها مرتب شده و در نمودار دیگری نمایش داده می‌شود. این دو روش به تحلیلگر کمک می‌کنند تا ویژگی‌هایی که بیشترین تأثیر را در پیش‌بینی ضریب انتقال حرارت دارند شناسایی کرده و بر اساس آن‌ها تصمیم‌گیری‌های بهتری برای بهبود مدل انجام دهد.



شکل ۱.۶ بررسی مهم‌ترین ویژگی‌ها براساس Random Forest



شکل ۲.۶ بررسی مهم‌ترین ویژگی‌ها براساس رگرسیون خطی



شکل ۳.۶ بررسی مهم‌ترین ویژگی‌ها براساس اهمیت جایگشت

۳.۶ تحلیل نهایی و پیشنهادات برای بهبود مدل

۱.۳.۶ تحلیل نهایی عملکرد مدل‌ها

با توجه به معیارهای ارزیابی مانند MAE ، MSE و R^2 ، عملکرد مدل‌ها در پیش‌بینی ضریب انتقال حرارت به شرح زیر ارزیابی شد:

رگرسیون خطی: این مدل در مواقعی که رابطه بین ویژگی‌ها و هدف غیرخطی باشد، عملکرد ضعیفی دارد، زیرا قادر به شبیه‌سازی روابط پیچیده نیست. MSE و MAE مدل بالا خواهد بود و R^2 پایین خواهد بود.

رگرسیون چندجمله‌ای: این مدل می‌تواند در مواقعی که ویژگی‌ها با هدف رابطه غیرخطی دارند، بهتر عمل کند. با این حال، استفاده از پلی‌نوم‌های با درجه بالاتر می‌تواند منجر به اورفیتینگ شود و مدل را قادر به تعمیم‌سازی صحیح برای داده‌های آزمون نکند.

درخت تصادفی: این مدل به خوبی می‌تواند روابط پیچیده غیرخطی را مدل‌سازی کند و معمولاً کمترین MSE و MAE و بالاترین R^2 را خواهد داشت.

شبکه عصبی: شبکه‌های عصبی می‌توانند در داده‌های پیچیده و با ابعاد بالا عملکرد خوبی داشته باشند، اما نیاز به داده‌های بیشتر و تنظیمات دقیق دارند تا از اورفیتینگ جلوگیری کنند. در این صورت، مدل می‌تواند پیش‌بینی‌های دقیقی ارائه دهد.

۲.۳.۶ مقایسه مدل‌ها و انتخاب بهترین مدل

با توجه به معیارهای MAE ، MSE و R^2 ، به نظر می‌رسد که درخت تصادفی بهترین مدل برای پیش‌بینی ضریب انتقال حرارت باشد. این مدل به دلیل توانایی در مدل‌سازی روابط پیچیده غیرخطی و مقاومت در برابر اورفیتینگ، عملکرد بسیار بهتری نسبت به دیگر مدل‌ها ارائه داد. شبکه عصبی نیز می‌تواند گزینه خوبی باشد، اما ممکن است نیاز به داده‌های بیشتری برای بهبود عملکرد و تنظیمات دقیق‌تر داشته باشد. رگرسیون چندجمله‌ای ممکن است در برخی موارد مفید باشد، اما استفاده از درجه‌های بالا ممکن است به اورفیتینگ منجر شود.

۳.۳.۶ پیشنهادات برای بهبود مدل‌ها

تنظیم هایپرپارامترها: با استفاده از GridSearchCV یا RandomizedSearchCV می‌توان هایپرپارامترهای مدل‌ها مانند تعداد درخت‌ها در درخت تصادفی، عمق درخت‌ها، و پارامترهای شبکه عصبی را بهینه کرد.

مهندسی ویژگی‌ها: استفاده از ویژگی‌های تعامل یا ویژگی‌های چندجمله‌ای (درجه ۲ یا ۳) می‌تواند به بهبود دقت مدل کمک کند. همچنین، استفاده از تحولات لگاریتمی یا مقیاس‌دهی ممکن است مدل‌هایی مانند شبکه‌های عصبی را بهبود بخشد.

اعتبارسنجی متقابل (Cross-validation): استفاده از K-fold cross-validation می‌تواند به کاهش ریسک اورفیتینگ کمک کند و ارزیابی دقیق‌تری از عملکرد مدل فراهم آورد.

افزایش داده‌ها: برای شبکه‌های عصبی، استفاده از تکنیک‌های افزایش داده‌ها یا جمع‌آوری داده‌های بیشتر می‌تواند کمک کند تا مدل از دقت بالاتری برخوردار شود.

مدل‌های ترکیبی: استفاده از روش‌های تجمیعی مانند تصادفی‌بازی (stacking) یا رای‌گیری (voting) می‌تواند قدرت مدل‌ها را ترکیب کرده و به پیش‌بینی دقیق‌تری منجر شود.

۴.۳.۶ نتیجه

مدل بهترین: بر اساس تحلیل معیارهای MSE، MAE و R^2 ، درخت تصادفی احتمالاً بهترین مدل برای پیش‌بینی ضریب انتقال حرارت است. این مدل به‌خوبی از داده‌ها یاد می‌گیرد و به راحتی قادر به مدل‌سازی روابط پیچیده غیرخطی است.

کارهای آینده: برای بهبود بیشتر مدل، استفاده از ویژگی‌های اضافی (بر اساس دانش دامنه)، بهبود تنظیمات هایپرپارامترها، و افزایش داده‌ها می‌تواند به دقت پیش‌بینی‌ها کمک کند. با تمرکز بر این جنبه‌ها، می‌توان دقت و پایداری مدل را افزایش داده و پیش‌بینی‌های بهتری برای ضریب انتقال حرارت در کاربردهای مختلف مهندسی انجام داد.

